

ANTEPROYECTO GRUPO 2 - LOS PREDICTORES

Programa: Ingeniería de Sistemas

Modalidad: Presencial

Asignatura: Proyecto integrador I

Código: 2508700

Grupo: Grupo 2 - Los Predictores

Título del proyecto: Resumidor inteligente de artículos científicos

Tipo de proyecto: Desarrollo

Integrantes:

Naneth Giseth Martelo Montoya - naneth.martelo@udea.edu.co

Carlos Alberto Forero Agudelo - carlos.forero@udea.edu.co

Elio Esteban Mercado Londoño - elio.mercado@udea.edu.co

Profesor: Antonio Jesus Tamayo Herrera - antonio.tamayo@udea.edu.co

RESUMEN

La producción científica crece a una tasa cercana al 4,1 % anual (Bornmann et al., 2021) y solo arXiv acumula más de 3,1 millones de artículos (arXiv, 2026), un volumen que desborda la capacidad de lectura de los investigadores (Tenopir et al., 2015). El caso más crítico es el dominio clínico: se publican del orden de 75 ensayos controlados y 11 revisiones sistemáticas al día (Bastian et al., 2010), de modo que mantener actualizada la evidencia que sustenta las decisiones asistenciales es inviable de forma manual. Por ello el resumen automático de artículos biomédicos se ha consolidado como una de las aplicaciones más útiles de esta tarea, aunque los modelos generativos aún presentan inconsistencias factuales y pérdida de información saliente al procesar documentos extensos (Tang et al., 2023). La restricción es más severa en la etapa inicial de un proyecto, donde deben cribarse cientos de artículos y el costo por documento pesa más que la calidad marginal del resumen.

Los artículos científicos promedian 4.938 palabras (Cohan et al., 2018), muy por encima de la ventana de 1.024 tokens de BART o PEGASUS, y las arquitecturas de secuencia larga como LED y LongT5 levantan esa restricción a costa de mayor latencia, memoria e infraestructura. Este proyecto desarrolla un resumidor de artículos científicos desplegado en producción y de acceso público, que combina modelos preentrenados de contexto corto con estrategias de manejo de contexto largo —truncamiento, Map-Reduce y extractivo-abstractivo— y las compara estadísticamente sobre un banco de artículos con resúmenes de referencia mediante ROUGE-1, ROUGE-2, ROUGE-Lsum y BERTScore junto con latencia, pico de memoria y ratio de compresión, entregando un criterio empírico de selección bajo restricciones de cómputo.

PALABRAS CLAVE (*Key words*)

Resumen abstractivo; procesamiento de lenguaje natural; modelos de lenguaje pre-entrenados; ventana de contexto; documentos científicos largos; compromiso calidad-coste computacional.

Key words: abstractive summarization; natural language processing; pretrained language models; context window; long scientific documents; quality-cost trade-off.

PLANTEAMIENTO DEL PROBLEMA

La literatura científica crece a una tasa anual del 4,10 %, con un tiempo de duplicación de 17,3 años (Bornmann et al., 2021), y solo arXiv acumula más de 3,13 millones de artículos (arXiv,

2026), mientras que la capacidad de lectura por investigador se estabilizó en torno a 264 artículos al año (Tenopir et al., 2015). El desbalance es más crítico en la etapa inicial de un proyecto —revisión exploratoria, cribado y priorización—, donde el objetivo no es comprender cada artículo en profundidad sino decidir con rapidez cuáles justifican una lectura completa: allí el sistema debe procesar cientos de documentos y el costo por documento, más que la calidad marginal del resumen, se convierte en la restricción dominante.

Esta presión es particularmente aguda en el dominio clínico y biomédico, donde el volumen de evidencia y su velocidad de renovación condicionan directamente la práctica: hacia 2010 ya se publicaban cerca de 75 ensayos controlados y 11 revisiones sistemáticas diarias (Bastian et al., 2010), una tasa incompatible con la elaboración manual de síntesis de evidencia. Por eso el resumen automático de literatura biomédica es hoy una de las aplicaciones de mayor impacto de la tarea, con casos de uso concretos en el cribado de estudios para revisiones sistemáticas y en la actualización de guías de práctica clínica. Sin embargo, su evaluación reciente muestra que los modelos generativos incurren en inconsistencias factuales y omiten información saliente precisamente cuando el documento de entrada es largo (Tang et al., 2023), lo que confirma que la longitud del documento —y no solo la capacidad del modelo— es el factor determinante y refuerza la pertinencia de estudiar explícitamente las estrategias de manejo de contexto que aborda este proyecto.

Automatizar esa tarea enfrenta una restricción estructural: los artículos científicos promedian 4.938 palabras, frente a las 656–693 de los corpus periodísticos sobre los que se validaron muchos de estos modelos (Cohan et al., 2018), mientras que BART (Lewis et al., 2020) y PEGASUS (Zhang et al., 2020a) operan con ventanas de 1.024 tokens, porque la autoatención del Transformer escala cuadráticamente con la longitud de la secuencia (Beltagy et al., 2020). Las arquitecturas de secuencia larga (LED, Beltagy et al., 2020; LongT5, Guo et al., 2022) levantan esa restricción, pero desplazan el problema al costo —mayor pico de memoria, mayor latencia y hardware del que no disponen la mayoría de grupos de investigación en la región—, un costo que escala linealmente al cribar cientos de artículos. La alternativa es adaptar el documento al modelo mediante truncamiento, Map-Reduce o preselección extractiva, empleando modelos de contexto corto ya preentrenados, sin fine-tuning, a un costo por documento sustancialmente menor.

La premisa que motiva este proyecto es que, para etapas tempranas de análisis, esa segunda vía ofrece un compromiso calidad-costo suficiente y constituye una alternativa viable a los modelos de contexto largo. No existe, sin embargo, evidencia que permita verificarlo: cada trabajo reporta resultados sobre datos, configuraciones y hardware distintos, y casi exclusivamente bajo métricas de calidad como ROUGE (Lin, 2004) o BERTScore (Zhang et al., 2020b), indiferentes a la latencia, al consumo de memoria y al ratio de compresión. Sin ese criterio, el truncamiento puede descartar los resultados y conclusiones que determinan la pertinencia del artículo, y adoptar por defecto arquitecturas largas incrementa el costo de infraestructura sin garantía de retorno, trasladando la decisión de diseño a la popularidad del modelo antes que a la evidencia.

El proyecto es, por tanto, de desarrollo: su producto final es un resumidor de artículos científicos desplegado en producción y accesible públicamente, cuya configuración —modelo y estrategia de manejo de contexto— se selecciona a partir de evidencia experimental propia. Abordarlo exige competencias propias del ingeniero de sistemas: diseñar un sistema

experimental reproducible, integrar modelos preentrenados y canalizaciones de procesamiento de texto, instrumentar la medición de latencia y memoria, analizar estadísticamente los resultados y llevar el sistema resultante a un despliegue operativo bajo restricciones de cómputo definidas.

Marco teórico

El Procesamiento de Lenguaje Natural (PLN) es un campo de la inteligencia artificial dedicado al análisis y generación del lenguaje humano. Dentro de este campo se encuentra el resumen automático, cuyo objetivo es generar una versión reducida de un documento conservando la información relevante. El resumen puede ser extractivo, cuando selecciona fragmentos del texto original, o abstractivo, cuando genera nuevo contenido a partir de la información del documento. El presente proyecto se centra en el resumen abstractivo de artículos científicos extensos, en los cuales la cantidad de información puede superar la capacidad de procesamiento de los modelos de lenguaje preentrenados utilizados.

Los modelos modernos de resumen automático se encuentran principalmente relacionados con la arquitectura Transformer, la cual utiliza mecanismos de atención para identificar las partes relevantes de una secuencia. Sin embargo, los modelos basados en esta arquitectura pueden presentar restricciones en la cantidad de tokens que procesan simultáneamente. Esta limitación resulta especialmente relevante al trabajar con artículos científicos extensos, ya que un documento puede superar ampliamente la ventana de contexto disponible en modelos preentrenados de contexto corto.

Entre los modelos encoder-decoder preentrenados utilizados para tareas de generación y resumen se encuentran BART y PEGASUS. BART emplea un proceso de corrupción y reconstrucción del texto durante su preentrenamiento, mientras que PEGASUS fue diseñado específicamente para el resumen abstractivo mediante la identificación y eliminación de oraciones importantes que posteriormente deben ser generadas por el modelo. Estos modelos permiten realizar inferencia utilizando pesos previamente entrenados, sin necesidad de entrenar un modelo desde cero.

La ventana de contexto representa la cantidad máxima de tokens que un modelo puede recibir o considerar durante una operación. Cuando un artículo científico supera esta capacidad, es necesario utilizar estrategias que permitan adaptar el documento al límite del modelo. Una alternativa es el truncamiento, mediante el cual se conserva únicamente una parte del documento; aunque esta estrategia presenta un bajo costo computacional, puede provocar la pérdida de información relevante. Otra posibilidad consiste en dividir el documento en fragmentos que puedan ser procesados individualmente y posteriormente combinar sus resultados. Esta estrategia puede implementarse mediante enfoques como Map-Reduce, donde primero se generan resúmenes parciales y posteriormente se obtiene un resumen global a partir de ellos.

Otra alternativa corresponde a los enfoques híbridos, en los cuales se realiza inicialmente una selección extractiva de las partes potencialmente relevantes del documento y posteriormente se utiliza un modelo abstractivo para generar el resumen. Estas estrategias permiten reducir la

cantidad de información que debe procesar el modelo generativo y constituyen una alternativa para trabajar con documentos extensos sin modificar los pesos de los modelos preentrenados.

La literatura también presenta modelos especializados en el procesamiento de secuencias largas, como Longformer Encoder-Decoder (LED) y LongT5. LED modifica el mecanismo de atención para permitir el procesamiento de secuencias más extensas, mientras que LongT5 incorpora mecanismos orientados al manejo eficiente de entradas largas. Estas propuestas evidencian que el procesamiento de documentos extensos constituye un problema relevante dentro del resumen automático. Sin embargo, el presente proyecto se enfoca en estudiar estrategias que permitan utilizar modelos preentrenados de contexto corto, en lugar de desarrollar o utilizar exclusivamente modelos diseñados para ventanas de contexto extensas.

Para evaluar la calidad de los resúmenes generados se utilizan métricas como ROUGE-1, ROUGE-2 y ROUGE-Lsum, que permiten medir diferentes niveles de coincidencia entre un resumen generado y uno de referencia. ROUGE-1 evalúa la coincidencia de unigramas, ROUGE-2 considera secuencias de dos palabras y ROUGE-L se relaciona con la coincidencia de subsecuencias de palabras. Debido a que estas métricas dependen principalmente de coincidencias léxicas, también se considera BERTScore, que utiliza representaciones contextuales para evaluar la similitud semántica entre los textos.

La evaluación del sistema no se limita a la calidad de los resúmenes, sino que también considera el costo computacional asociado a cada estrategia. Para ello se pueden analizar variables como la latencia p50 y p95, el consumo máximo de memoria y el ratio de compresión. La latencia permite evaluar el tiempo requerido para procesar los documentos, mientras que el consumo de memoria permite determinar los recursos necesarios durante la inferencia. Por su parte, el ratio de compresión relaciona la longitud del documento original con la longitud del resumen generado y permite determinar qué tan efectivamente se reduce la extensión del contenido.

A partir de las alternativas identificadas, el proyecto plantea comparar diferentes combinaciones de modelos preentrenados de contexto corto y estrategias de procesamiento de documentos extensos, considerando tanto la calidad de los resultados como los recursos computacionales requeridos. De esta manera, el propósito no es únicamente obtener el resumen con mayor calidad, sino establecer experimentalmente qué estrategia presenta el mejor compromiso entre calidad, tiempo de procesamiento, consumo de memoria y capacidad de compresión del documento.

Finalmente, el sistema será complementado con una plataforma web que permitirá al usuario cargar artículos científicos, seleccionar opciones predefinidas de procesamiento y obtener los resúmenes generados. La plataforma integrará las estrategias y modelos evaluados, permitiendo utilizar el sistema como un producto funcional y facilitando la comparación de las diferentes alternativas de resumen.

OBJETIVO GENERAL

Desarrollar un sistema de resumen automático de artículos científicos que integre diferentes estrategias de procesamiento de documentos extensos con modelos de lenguaje preentrenados de contexto corto, junto con una plataforma web para su utilización, con el

propósito de generar resúmenes de calidad y determinar la alternativa que presente el mejor compromiso entre calidad del resultado y costo computacional.

OBJETIVOS ESPECÍFICOS

1. **Analizar** las técnicas y modelos de resumen automático aplicables al procesamiento de artículos científicos extensos mediante modelos de lenguaje preentrenados de contexto corto.
2. **Realizar** el preprocesamiento y análisis exploratorio de los artículos científicos, identificando características como extensión, cantidad de tokens, estructura y distribución del contenido, con el fin de establecer estrategias adecuadas para su procesamiento.
3. **Diseñar** la arquitectura del sistema de resumen automático considerando las limitaciones de contexto de los modelos seleccionados y los requerimientos funcionales y técnicos del proyecto.
4. **Implementar** diferentes estrategias de procesamiento de artículos científicos extensos que permitan adaptar su contenido a las ventanas de contexto de los modelos preentrenados.
5. **Implementar** un mecanismo de evaluación que permita medir la calidad de los resúmenes generados y el costo computacional asociado a cada estrategia.
6. **Determinar** la configuración que presente el mejor compromiso entre la calidad de los resúmenes generados y el costo computacional requerido.
7. **Validar experimentalmente** el funcionamiento del sistema mediante la comparación de los modelos y estrategias implementados, considerando métricas de calidad y costo computacional.
8. **Desarrollar** una plataforma web que permita al usuario cargar artículos científicos, seleccionar opciones predefinidas de procesamiento y obtener los resúmenes generados por el sistema.
9. **Validar** la funcionalidad y el cumplimiento de los requerimientos del software como producto final, verificando la correcta integración de sus componentes, el funcionamiento de la plataforma web y la generación de resúmenes de acuerdo con las funcionalidades definidas para el proyecto.


METODOLOGÍA

El proyecto tendrá un enfoque cuantitativo y aplicado, orientado al desarrollo y evaluación de un sistema de resumen automático de artículos científicos extensos utilizando modelos de contexto corto. Inicialmente, se realizará la revisión de las técnicas y modelos de resumen seleccionados, seguida del preprocesamiento y análisis exploratorio del conjunto de artículos, considerando su extensión, cantidad de tokens y estructura. Posteriormente, se diseñará e implementará el sistema, integrando las estrategias de procesamiento de documentos y los modelos preentrenados seleccionados, junto con un mecanismo de evaluación basado en las métricas ROUGE-1, ROUGE-2, ROUGE-Lsum y BERTScore, complementadas con indicadores de costo computacional como latencia, pico de memoria y ratio de compresión. A partir de los resultados obtenidos, se determinará la alternativa que presente el mejor compromiso entre calidad de los resúmenes y costo computacional, de acuerdo con las restricciones establecidas para el proyecto. Finalmente, se desarrollará la plataforma web para la utilización del sistema y se realizará su validación funcional, verificando la integración de sus componentes, el cumplimiento de los requerimientos definidos y la correcta generación de los resúmenes.

CRONOGRAMA

CRONOGRAMA – 16 SEMANAS

Sistema de resumen automático de artículos científicos extensos con modelos de contexto corto



PRESUPUESTO

RUBROS	FUENTES		TOTAL
	UdeA	Otras fuentes	
PERSONAL	Equipo: 8h*16sem*\$30.000* 3 = \$11.520.000 Asesor: 2h*16sem*\$120.000 = \$3.840.000	\$0	\$15.360.000
EQUIPOS	\$1.170.000	\$0	\$1.170.000
SOFTWARE	\$0	\$0	\$0
MATERIAL BIBLIOGRÁFICO	\$0	\$0	\$0
SERVICIOS TÉCNICOS	\$0	\$1.350.000	\$1.350.000
TOTAL	\$16.530.000	\$1.350.000	\$17.880.000

Otras fuentes: recursos propios del equipo

Internet: \$200.000
Electricidad: \$150.000
Cómputo en la nube: \$1.000.000

BIBLIOGRAFÍA

arXiv. (2026). *arXiv monthly submissions statistics*. Cornell University. https://arxiv.org/stats/monthly_submissions

Beltagy, I., Peters, M. E., & Cohan, A. (2020). Longformer: The long-document transformer. *arXiv*. <https://arxiv.org/abs/2004.05150>

Bornmann, L., Haunschild, R., & Mutz, R. (2021). Growth rates of modern science: A latent piecewise growth curve approach to model publication numbers from established and new literature databases. *Humanities and Social Sciences Communications*, 8, 224. <https://doi.org/10.1057/s41599-021-00903-w>

Cohan, A., Deroncourt, F., Kim, D. S., Bui, T., Kim, S., Chang, W., & Goharian, N. (2018). A discourse-aware attention model for abstractive summarization of long documents. *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 2, 615–621. <https://aclanthology.org/N18-2097/>

Empresas Públicas de Medellín E.S.P. (EPM). (2026). *Tarifas de energía EPM 2026*. <https://www.epm.com.co/clientesyusuarios/energia/tarifas-energia/>

Guo, M., Ainslie, J., Uthus, D., Ontañón, S., Ni, J., Sung, Y.-H., & Yang, Y. (2022). LongT5: Efficient text-to-text transformer for long sequences. *Findings of the Association for Computational Linguistics: NAACL 2022*. <https://arxiv.org/abs/2112.07916>

HP Inc. (2026). *Computadores portátiles HP*. HP Colombia.

Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., Mohamed, A., Levy, O., Stoyanov, V., & Zettlemoyer, L. (2020). BART: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 7871–7880. <https://arxiv.org/abs/1910.13461>

Lin, C.-Y. (2004). ROUGE: A package for automatic evaluation of summaries. In *Text summarization branches out* (pp. 74–81). Association for Computational Linguistics. <https://aclanthology.org/W04-1013/>

Tenopir, C., King, D. W., Christian, L., & Volentine, R. (2015). Scholarly article seeking, reading, and use: A continuing evolution from print to electronic in the sciences and social sciences. *Learned Publishing*, 28(2), 93–105. <https://doi.org/10.1087/20150203>

Zhang, J., Zhao, Y., Saleh, M., & Liu, P. J. (2020). PEGASUS: Pre-training with extracted gap-sentences for abstractive summarization. *Proceedings of the 37th International Conference on Machine Learning*, 119, 11328–11339. <https://arxiv.org/abs/1912.08777>

Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2020). BERTScore: Evaluating text generation with BERT. *International Conference on Learning Representations*. <https://arxiv.org/abs/1904.09675>

Bastian, H., Glasziou, P., & Chalmers, I. (2010). Seventy-five trials and eleven systematic reviews a day: How will we ever keep up? *PLoS Medicine*, 7(9), e1000326. <https://doi.org/10.1371/journal.pmed.1000326>

Tang, L., Sun, Z., Ilday, B., Nestor, J. G., Soroush, A., Elias, P. A., Xu, Z., Ding, Y., Durrett, G., Rousseau, J. F., Weng, C., & Peng, Y. (2023). Evaluating large language models on medical evidence summarization. *npj Digital Medicine*, 6, 158. <https://doi.org/10.1038/s41746-023-00896-7>